

# Predição de Sintomas Osteomusculares em Docentes com Machine Learning

Uso de modelos preditivos para apoiar ações preventivas na saúde ocupacional

Felipe

*Departamento de Informática*

*Universidade Federal do Espírito Santo*

Vitória, Brasil

felipe@gmail.com

Paulo Roberto de Lacerda

*Departamento de Informática*

*Universidade Federal do Espírito Santo*

Vitória, Brasil

paulo.lacerda@ufes.br

Daniel José Ventrorm Nunes

*Departamento de Informática*

*Universidade Federal do Espírito Santo*

Vitória, Brasil

danielventorim@gmail.com

**Resumo**—Este trabalho propõe um modelo de Machine Learning para prever a incidência de sintomas osteomusculares em docentes da rede pública de Santa Catarina, com base em dados demográficos e ocupacionais. Após pré-processamento e codificação one-hot de variáveis categóricas, sete classificadores supervisionados foram avaliados: Decision Tree, SVM, Regressão Logística, Random Forest, KNN, Gaussian NB e MLPClassifier. O modelo Random Forest destacou-se com a melhor acurácia no teste (81,8%) e maior F1-Score (0,769), demonstrando boa generalização e ausência de overfitting. A análise SHAP indicou que fatores como cidade, regime de trabalho e idade são os mais influentes na predição. Os resultados evidenciam o potencial do uso de modelos preditivos para apoiar ações preventivas na saúde docente.

## I. INTRODUÇÃO

A função docente tem se tornado cada vez mais complexa, extrapolando os limites da sala de aula para incluir planejamento curricular, gestão escolar, atividades extracurriculares além de disponibilidade online. Esse acúmulo de tarefas tem contribuído para um intenso desgaste físico e mental, tornando os professores um grupo de risco para agravos à saúde ocupacional [1].

Entre esses agravos, os sintomas osteomusculares destacam-se por sua alta prevalência. Estudos indicam que até 60% dos docentes relatam dores nas costas, pescoço e membros superiores, frequentemente associadas à postura prolongada, sobrecarga de trabalho e estresse [5]. A prevalência de doenças musculoesqueléticas está em aumento em todo o mundo e espera-se que aumente ainda mais no futuro, causando incapacidade substancial e sobrecarga para indivíduos e sociedades [6]. De acordo com o Estudo Global sobre Carga de Doenças, Lesões e Fatores de Risco de 2019, o número de pessoas vivendo com condições musculoesqueléticas era de cerca de 1,714 bilhão em todo o mundo, e uma tendência crescente (em média 62%) tem sido observada em todos os grupos de doenças MSK desde 1990 [11].

Um estudo realizado pelo Instituto Federal de Santa Catarina avaliou a prevalência de sintomas osteomusculares, nível de estresse e qualidade de vida de professores do ensino básico. A amostra foi composta de 298 professores (265

mulheres e 33 homens) da educação infantil e fundamental do município de Caçador, Santa Catarina.

Os resultados mostraram alta prevalência de sintomas osteomusculares e de estresse, com predomínio de professores se aproximando da exaustão [5]. Porém, professores com distúrbios vocais e professores com vozes saudáveis não apresentam diferenças quanto à frequência e intensidade da dor musculoesquelética, indicando que a dor é um sintoma que deve ser considerado em docentes, independentemente da presença de distúrbios vocais. No entanto, as variáveis ocupacionais contribuíram para a presença de dor próxima à laringe, que parece ser diretamente proporcional ao tempo de jornada semanal [7].

Apesar da gravidade do problema, a literatura carece de modelos preditivos capazes de identificar professores em risco de forma proativa. A maioria dos estudos se limita à análise descritiva de dados coletados por meio de Questionários, e, embora o uso de Machine Learning (ML) tenha crescido em áreas da saúde, sua aplicação na prevenção de agravos ocupacionais em docentes ainda é incipiente.

Diante disso, este trabalho propõe um modelo de Machine Learning para prever a incidência de sintomas osteomusculares em docentes da rede pública de Santa Catarina, utilizando dados demográficos e ocupacionais. Após o pré-processamento dos dados, sete classificadores supervisionados foram avaliados: Decision Tree, SVM, Regressão Logística, Random Forest, KNN, Gaussian NB e MLPClassifier. Neste estudo usamos também a análise SHAP foi empregada para interpretar as decisões do modelo, identificando as variáveis mais influentes.

## II. TRABALHOS CORRELATOS

Para organizar melhor os trabalhos correlatos, destacamos inicialmente estudos que abordam diretamente desfechos relacionados a problemas osteomusculares em professores. Em seguida, apresentamos pesquisas que aplicam técnicas de aprendizado de máquina na predição de agravos osteomusculares.

### A. Problemas Osteomusculares

A alta prevalência de sintomas osteomusculares entre docentes é um problema global de saúde ocupacional. Estudos indicam que fatores como jornada de trabalho, postura prolongada e estresse estão fortemente associados a esses agravos [8]. Um estudo com professores em atividade mostrou que, mesmo na ausência de distúrbios vocais, a dor musculoesquelética é comum, sendo diretamente proporcional ao tempo de jornada semanal [8]. Isso reforça a necessidade de estratégias preventivas que considerem o desgaste ocupacional de forma holística.

### B. Aprendizado de Máquina em Saúde Ocupacional

O uso de Machine Learning para a predição de doenças ocupacionais tem ganhado destaque. Jung et al. [9] aplicaram modelos como Random Forest e XGBoost para prever a relação de trabalho com distúrbios do ombro, alcançando alta acurácia e demonstrando o potencial do ML para apoiar decisões de compensação. Da mesma forma, Matos et al. [10] propuseram um sistema proativo que combina captura de movimento e aprendizado de máquina para prevenir lesões em trabalhadores industriais, destacando a viabilidade de intervenções baseadas em dados.

Embora esses estudos demonstrem o potencial do ML em contextos ocupacionais, nenhum se concentra especificamente na categoria docente, um grupo com alta carga de trabalho e risco elevado de sintomas. Este trabalho preenche essa lacuna ao aplicar e comparar múltiplos classificadores supervisionados para prever sintomas osteomusculares em professores, com foco em interpretabilidade e aplicabilidade prática.

## III. METODOLOGIA

### A. Seleção e Preparação dos Dados

Os dados utilizados neste estudo foram os coletados por meio do **Questionário Nórdico de Sintomas Osteomusculares**, aplicado a docentes da rede pública de Santa Catarina. Após análise comparativa de diferentes tabulações, optou-se por utilizar esses dados devido à sua maior consistência e completude.

Esses questionários foram tabulados e disponibilizados em planilhas do Excel, com todas as características observadas no formato texto como matra a Tabela I — um fator limitante para algoritmos de regressão e classificação, que exigem entrada numérica.

Para superar essa limitação, foi aplicada a técnica de *One-Hot Encoding*, que transforma cada categoria em uma coluna binária (0 ou 1), evitando a imposição de uma hierarquia artificial entre as classes. Essa abordagem permite que algoritmos de Machine Learning interpretem corretamente variáveis categóricas, como sexo, idade e carga horária, sem assumir ordens ou escalas inexistentes.

A Tabela II apresenta as colunas resultantes após o pré-processamento, totalizando 28 variáveis binárias.

### B. Configuração dos Modelos

Foram avaliados sete classificadores supervisionados da biblioteca `scikit-learn`: **Decision Tree**, **SVM**, **Regressão Logística**, **Random Forest**, **KNN**, **Gaussian NB** e **MLPClassifier**. Todos os modelos foram treinados com um valor fixo de `random_state=2025`, garantindo a **reprodutibilidade** dos resultados.

Os hiperparâmetros foram ajustados com base nas recomendações da biblioteca e em testes preliminares e com a validação cruzada. O desempenho dos modelos foi avaliado em relação à acurácia no conjunto de treinamento e teste, com o objetivo de identificar e evitar o *overfitting*. Modelos com grande discrepância entre esses valores indicam possível *overfitting*.

A Tabela III apresenta o desempenho dos modelos em relação às métricas de **acurácia (treino e teste)**, **precision**, **recall** e **F1-Score**.

Tabela I: Descrição das colunas do conjunto de dados

#	Coluna	Não-Nulos	Tipo
0	Cidade	218	object
1	Sexo	218	object
2	Idade	218	object
3	Estado Civil	218	object
4	Filhos	218	object
5	Escolaridade	218	object
6	Tempo de atuação	218	object
7	Vínculo de trabalho	218	object
8	Carga horária semanal	218	object
9	Turnos de trabalho semanal	218	object
10	Número de alunos por turma	218	object
11	Pluriemprego	218	object
12	Possui Sintomas Osteomusculares?	218	object

Após o tratamento inicial desses dados foi feito o *One-Hot Encoding*<sup>1</sup>, que é uma técnica usada para converter variáveis categóricas (como sexo "Masculino"/"Feminino", nomes de cidades, tipos de atividade, etc.) em um formato numérico binário (0s e 1s). Muitos algoritmos de Machine Learning (como regressão linear, redes neurais, etc.) O *one-hot encoding* permite representar esses dados de forma que o modelo possa interpretá-los corretamente, sem assumir uma ordem ou hierarquia entre as categorias [4].

### C. Escolha dos modelos

Como se trata de de um conjunto de dados categorizados, foram escolhidos 7 modelos de aprendizado supervisionado da biblioteca Scikit-Learn:

- 1) Decision Tree
- 2) SVM
- 3) Logistic Regression
- 4) Random Forest
- 5) KNN
- 6) Gaussian NB
- 7) MLPClassifier

<sup>1</sup>[https://github.com/paaatcha/MetaBlock/blob/main/benchmarks/pad/preprocess/prepare\\_data.py](https://github.com/paaatcha/MetaBlock/blob/main/benchmarks/pad/preprocess/prepare_data.py)

Tabela II: Tabela com os campos transformados após a execução do One-Hot Encoding

#	Coluna	Coluna	Nulos
0	Lebon Regis	218 non-null	int64
1	Paulo Lopes	218 non-null	int64
2	São Ludjero	218 non-null	int64
3	Videira	218 non-null	int64
4	Feminino	218 non-null	int64
5	Masculino	218 non-null	int64
6	Entre 31 e 40 anos	218 non-null	int64
7	Acima de 40 anos	218 non-null	int64
8	Até 30 anos	218 non-null	int64
9	estado_civil	218 non-null	int64
10	filhos	218 non-null	int64
11	Especialização	218 non-null	int64
12	Graduação	218 non-null	int64
13	Mestrado/Doutorado	218 non-null	int64
14	Até 10 anos	218 non-null	int64
15	Acima de 10 anos	218 non-null	int64
16	Efetivo	218 non-null	int64
17	ACT	218 non-null	int64
18	Até 20 horas	218 non-null	int64
19	De 21 a 40 horas	218 non-null	int64
20	Acima de 40 horas	218 non-null	int64
21	2 turnos	218 non-null	int64
22	1 turnos	218 non-null	int64
23	3 turnos	218 non-null	int64
24	Até 30 alunos	218 non-null	int64
25	Acima de 30 alunos	218 non-null	int64
26	pluriemprego	218 non-null	int64
27	sintomas_osteomusculares	218 non-null	int64




Figura 1: Gráfico Shap.

#### D. Configuração inicial dos modelos

Todos os modelos foram treinados definindo um valor para `random_state`, com isso o modelo pode ser reproduzido exatamente como está sendo apresentado. Os parâmetros foram alterados seguindo a possibilidades e recomendações da biblioteca do Scikit-learn. O desempenho dos modelos configurados manualmente estão apresentados na tabela III, com os valores de accuracy, precision, recall, e f1-score, a acurácia (*accuracy*) foi medida tanto para o conjunto de treinamento quanto para o conjunto de teste para ter um parâmetro de avaliação de *overfitting*. Modelos com valores de acurácia de treinamento e teste muito distantes podem representar *overfitting*.

A figura 2 mostra todas as matrizes de confusão normalizadas para cada modelo usado.

Com base na tabela III, é possível fazer uma análise detalhada do desempenho dos modelos de classificação em termos de acurácia, generalização, equilíbrio entre *precision* e *recall*, e tendência a *overfitting*, o que permite afirmar que o *Random Forest* foi o melhor modelo, com maior acurácia no teste (0.818), superior aos demais, melhor F1-Score (0.769), que indica o melhor equilíbrio entre *precision* e *recall*, acurácia de treino (0.800) ligeiramente menor que a de teste, sem *overfitting*, e sugere boa estabilidade. O *Random Forest* se mostrou o modelo mais confiável e eficaz para este problema. O gráfico shap 1, que atribui um valor a cada característica para explicar quanto e em que direção ela influenciou a previsão do modelo para cada instância, mostra quais fatores, do topo para baixo, mais influenciam a previsão de sintomas osteomusculares.

Os modelos *SVM*, *Logistic Regression* e *Gaussian NB* tiveram desempenho semelhante, todos apresentaram Acurácia no conjunto de teste = 0.7576, *Precision* = *Recall* = *F1-Score* = 0.6923, que indica um desempenho consistente e equilibrado entre as métricas, uma boa generalização (sem *overfitting*). São boas opções como modelos baseline, especialmente se a simplicidade ou baixo custo computacional for prioridade, que não é o caso desse trabalho por lidar com um conjunto pequeno de dados. A diferença é que o SVM tem acurácia de treino maior (0.816).

Os modelos *KNN* e *MLPClassifier* apresentam forte *overfitting*, o KNN com acurácia do conjunto de treinamento de 0.962, muito alta, acurácia de teste = 0.697, uma queda de 26.5 pontos e F1-Score de 0.643 (baixo), o que leva a concluir que o modelo memorizou os dados de treino e falhou ao generalizar. Já o *MLPClassifier* (Rede Neural) apresentou acurácia de treino de 0.854 acurácia de teste de 0.697, uma queda de 15.7 pontos, e um F1-Score de 0.643, o que indica *overfitting* moderado a forte, comum em redes neurais com pouca regularização.

Já o modelo *Decision Tree* teve desempenho inferior com acurácia no teste de 0.727 (abaixo da média), F1-Score: 0.640 (mais baixo entre os modelos razoáveis). Apesar de não ter *overfitting* acentuado, não generalizou bem. O modelo *Decision Tree* se mostrou inferior ao *Random Forest*, mesmo sendo um modelo base dele, o que é esperado.

- 1) **Decision Tree:** O parâmetro `min_samples_leaf = 5` melhorou o resultado. A definição de um valor mínimo de amostras por folha pode prevenir *overfitting*, e o parâmetro `random_state` assegura a reprodutibilidade do modelo.

Tabela III: Desempenho dos modelos de classificação no conjunto de treino (TR) e teste (TE)

Modelo	Acurácia TR	Acurácia TE	Precisão	Recall	F1-Score
Decision Tree	0.783784	0.727273	0.666667	0.615385	0.640000
SVM	0.816216	0.757576	0.692308	0.692308	0.692308
Logistic Regression	0.751351	0.757576	0.692308	0.692308	0.692308
Random Forest	0.800000	0.818182	0.769231	0.769231	0.769231
KNN	0.962162	0.696970	0.600000	0.692308	0.642857
Gaussian NB	0.691892	0.757576	0.692308	0.692308	0.692308
MLPClassifier	0.854054	0.696970	0.600000	0.692308	0.642857

```
DecisionTreeClassifier(random_state=2025,
                       max_depth=10,
                       min_samples_leaf=5)
```

- 2) **SVM (SVC):** As alterações nos parâmetros padrão não surtiram efeito. Foram mantidos os valores *default*.

```
SVC(random_state=2025, C=1.0, kernel='rbf')
```

- 3) **Logistic Regression:** O *solver* liblinear é recomendado para pequenos conjuntos de dados. Outros solucionadores, como lbfgs, saga e newton-cg, apresentaram resultados similares.

```
LogisticRegression(random_state=2025,
                   penalty='l2',
                   solver='liblinear')
```

- 4) **Random Forest:** Os hiperparâmetros *max\_depth*, *min\_samples\_split* e *min\_samples\_leaf* contribuíram para a melhoria da acurácia.

```
RandomForestClassifier(random_state=2025,
                      n_estimators=100,
                      max_depth=10,
                      min_samples_split=5,
                      min_samples_leaf=3)
```

- 5) **KNN:**

```
KNeighborsClassifier(n_neighbors=20,
                   weights='distance',
                   metric='minkowski')
```

- 6) **Gaussian NB:**

```
GaussianNB(var_smoothing=0.65)
```

- 7) **MLPClassifier (Scikit-learn):**


```
MLPClassifier(random_state=2025,
              hidden_layer_sizes=(20,),
              max_iter=500)
```

### E. Validação Cruzada

Os primeiros testes da validação cruzada usando apenas 5 folders não apresentaram melhorias no modelo, o que era esperado para um conjunto de dados pequeno como é o caso dataset do questionário nórdico usado neste trabalho, em seguida a validação cruzada foi testada alterando o parâmetro CV para 15, valor que apresentou o melhor resultado.


Melhores parâmetros encontrados para o Random Forest: *max\_depth*: 10, *min\_samples\_leaf*: 5, *min\_samples\_split*: 2, *n\_estimators*: 50

Melhor Acurácia do cross-validation para o Random Forest: 0.7 Acurácia do conjunto de teste com melhor Acurácia com os melhores parâmetros do Random Forest: 0.8181818181818182.




(a) Decision Tree

(b) SVM




(c) Logistic Regression

(d) Random Forest



(e) KNN

(f) Gaussian NB



(g) MLPClassifier

Figura 2: Matrizes de Confusão normalizadas para diferentes modelos de classificação.

#### IV. TRABALHOS FUTUROS

Como trabalho futuro seria importante o uso do dataset completo dos questionários aplicados, neste primeiro momento não foram disponibilizados todos os questionários aplicados, o que pode ter prejudicado no treinamento do modelo. Outro trabalho seria fazer o uso do PyTorch para ter mais flexibilidade em relação aos modelos disponíveis além da possibilidade do uso de placas gráficas. Essas extensões poderão transformar o modelo analítico em um sistema ativo de promoção da saúde ocupacional docente.

#### V. RESULTADOS E DISCUSSÃO

##### A. Desempenho dos Modelos

A Tabela III apresenta o desempenho dos sete classificadores avaliados. O modelo Random Forest mostrou maior acurácia no conjunto de teste (81,8%) e o maior F1-Score (0,769), indicando um equilíbrio superior entre *precision* e *recall*. Além disso, sua acurácia no treinamento (80,0%) foi ligeiramente inferior à do teste, o que demonstra ausência de overfitting e boa capacidade de generalização.

Os modelos SVM, Regressão Logística e Gaussian NB apresentaram desempenho semelhante, com acurácia no teste de 75,8% e F1-Score de 0,692. Essa consistência sugere que, mesmo com abordagens diferentes, esses modelos alcançaram um bom nível de predição, adequado para conjuntos de dados de tamanho moderado.

Por outro lado, o KNN e o MLPClassifier apresentaram sinais claros de overfitting, com acurácias de treinamento de 96,2% e 85,4%, respectivamente, mas acurácias no teste de apenas 69,7%, o que indica memorização de dados de treinamento, mas falharam em generalizar para novas instâncias.

O **Decision Tree**, embora simples, obteve acurácia de teste de 72,7%, inferior à dos modelos *ensemble* e lineares, reforçando a vantagem do *Random Forest* como uma versão robusta e regularizada de árvores de decisão.

##### B. Análise das Matrizes de Confusão

A Figura 2 mostra as matrizes de confusão normalizadas para os modelos. O Random Forest apresentou a menor taxa de falsos negativos (23,1%) e a maior taxa de verdadeiros positivos (76,9%), o que é crucial em contextos de saúde, onde identificar corretamente indivíduos com sintomas é prioritário.

Em contraste, o KNN, apesar de alta acurácia no treino, apresentou alta taxa de falsos positivos (30%), o que poderia levar a muitas intervenções desnecessárias em professores saudáveis.

##### C. Interpretabilidade com SHAP

A análise SHAP (Figura 1) revelou que as variáveis mais influentes na predição foram:

1. Cidade (Lebon Regis, Paulo Lopes, São Ludjero, Videira)
2. Vínculo de trabalho (Efetivo vs. ACT)
3. Idade (Acima de 40 anos)
4. Turnos de trabalho (3 turnos)
5. Pluriemprego

Esses fatores estão diretamente ligados à sobrecarga ocupacional, reforçando achados da literatura sobre o impacto do regime de trabalho e da jornada excessiva na saúde docente [8].

A forte influência da variável "cidade" pode indicar diferenças regionais em condições de trabalho, infraestrutura escolar ou políticas locais de saúde, aspectos que merecem investigação futura, ou até mesmo problemas de equilíbrio no dataset.

##### D. Discussão dos Resultados

Os resultados confirmam o Random Forest como modelo mais adequado para prever sintomas osteomusculares em docentes. Sua capacidade de combinar múltiplas árvores e capturar interações não lineares entre variáveis o torna ideal para conjuntos de dados com alta dimensionalidade após o *One-Hot Encoding*.

A semelhança de desempenho entre SVM, Regressão Logística e Gaussian NB indica que, para este problema, modelos mais simples podem ser suficientes, embora não sejam os melhores. Já o overfitting do KNN e do MLPClassifier destaca a importância de regularização e validação cruzada rigorosa, especialmente em conjuntos de dados pequenos ( $n=218$ ).

A análise SHAP pode fornecer insights práticos para gestores educacionais: professores com vínculo precário, pluriemprego e múltiplos turnos são os mais vulneráveis, e intervenções direcionadas a esses grupos podem ter maior impacto preventivo.

#### VI. CONCLUSÃO

O modelo **Random Forest** demonstrou-se a melhor abordagem para a predição de sintomas osteomusculares em docentes, alcançando acurácia de 81,8% e F1-Score de 0,769 no conjunto de teste, com ausência de *overfitting* e bom equilíbrio entre *precision* e *recall*. A análise SHAP reforçou a importância de variáveis ocupacionais — como regime de trabalho, cidade e idade — como fatores-chave de risco, evidenciando a relação entre sobrecarga laboral e agravos à saúde. Modelos como KNN e MLPClassifier apresentaram forte **overfitting**, enquanto SVM, Regressão Logística e Gaussian NB, embora estáveis, tiveram desempenho inferior.

Apesar dos resultados promissores, o estudo tem limitações, como o tamanho reduzido do dataset ( $n=218$ ) e a falta de diversidade geográfica e institucional. No entanto, ele demonstra o potencial do Machine Learning para apoiar ações preventivas na saúde ocupacional docente, especialmente quando combinado com técnicas de explicabilidade. Recomenda-se, em trabalhos futuros, a expansão do dataset, o uso de modelos mais complexos (ex: PyTorch) e a integração com sistemas de alerta precoce em ambientes educacionais..

#### AGRADECIMENTO

Agradecemos ao Professor Ricelli Endrigo Ruppel da Rocha, do Instituto Federal de Santa Catarina, pela organização e disponibilização dos dados utilizados nesta pesquisa. Também reconhecemos as valiosas contribuições do Professor André Pacheco, cujas orientações e insights foram fundamentais para o desenvolvimento deste trabalho.

## REFERÊNCIAS

- [1] M. A. Darwish and S. Z. Al-Zuhair, "Musculoskeletal pain disorders among secondary school Saudi female teachers," *Pain Research and Treatment*, vol. 2013, p. 878570, 2013.
- [2] Scheuch K, Haufe E, Seibt R. Teachers' Health. *Dtsch Arztebl Int*. 2015 May 15;112(20):347-56. doi: 10.3238/arztebl.2015.0347. PMID: 26051692; PMCID: PMC4558646.
- [3] J. Shigemura, R. J. Ursano, J. C. Morganstein, M. Kurosawa, and D. M. Benedek, "Public responses to the novel 2019 coronavirus (2019-nCoV) in Japan: Mental health consequences and target populations," *Psychiatry and Clinical Neurosciences*, vol. 74, no. 4, p. 281, 2020.
- [4] T. Al-Shehari and R. A. Alsowail, "An insider data leakage detection using one-hot encoding, synthetic minority oversampling and machine learning techniques," *Entropy*, vol. 23, no. 10, p. 1258, 2021.
- [5] R. E. R. da Rocha, K. Prado Filho, F. N. da Silva, M. Boscarl, S. A. K. Amer, and D. C. de Almeida, "Sintomas osteomusculares e estresse n
- [6] E. Sebbag, R. Felten, F. Sagez, J. Sibilia, H. Devilliers, and L. Arnaud, "The world-wide burden of musculoskeletal diseases: a systematic analysis of the World Health Organization Burden of Diseases Database," *Annals of the Rheumatic Diseases*, vol. 78, no. 6, pp. 844–848, 2019.
- [7] A. Cieza, K. Causey, K. Kamenov, S. W. Hanson, S. Chatterji, and T. Vos, "Global estimates of the need for rehabilitation based on the Global Burden of Disease study 2019: a systematic analysis for the Global Burden of Disease Study 2019," *The Lancet*, vol. 396, no. 10267, pp. 2006–2017, 2020.
- [8] J. da Silva Vitor, L. T. D. S. Siqueira, V. V. Ribeiro, J. S. Ramos, A. G. Brasolotto, and K. C. A. Silverio, "Musculoskeletal Pain and Occupational Variables in Teachers With Voice Disorders and in Those With Healthy Voices—A Pilot Study," *Journal of Voice*, vol. 31, no. 4, pp. 518.e7–518.e13, 2017.
- [9] S. Jung et al., "Prediction of Work-relatedness of Shoulder Musculoskeletal Disorders as by Using Machine Learning," *Safety Science*, vol. 181, p. 106940, 2025.
- [10] L. M. Matos et al., "Proactive prevention of work-related musculoskeletal disorders using a motion capture system and time series machine learning," *Engineering Applications of Artificial Intelligence*, vol. 141, p. 107891, 2025.
- [11] A. Cieza et al., "Global estimates of the need for rehabilitation based on the Global Burden of Disease study 2019: a systematic analysis," *The Lancet*, vol. 396, no. 10267, pp. 2006–2017, 2020.